

UNIDAD 1: ALMACENAMIENTO DE LA INFORMACIÓN

Resumen de los 9 apartados principales | Guía breve pero completa para estudiar

Idea general. Toda aplicación necesita guardar, localizar y proteger datos. La unidad explica cómo se pasa de ficheros independientes a bases de datos gestionadas, distribuidas y analizadas.

1. Ficheros de información

Fichero: conjunto de datos relacionados y estructurados. Se compone de **registros** (cada elemento) y **campos** (sus propiedades). Una **clave** identifica registros. El sistema operativo mueve datos entre memoria y soporte en **bloques**; el número de registros lógicos que caben en un bloque es el factor de blocaje.

Tipos por función: permanentes: maestros (situación actual), constantes (referencia que cambia poco) e históricos (estados pasados). Temporales: intermedios (resultados que usa otro proceso), de maniobra (apoyo cuando falta memoria) y de resultados (salida). Los registros pueden ser de longitud fija, variable, delimitados o indefinida.

Soportes: acceso secuencial (cinta: hay que recorrer los datos previos) y acceso directo (discos/SSD: se salta a la posición). Para elegir organización se valoran capacidad, actividad de consulta/modificación, volatilidad (altas y bajas) y crecimiento.

Organización	Funcionamiento, ventajas y límites
Secuencial	Registros contiguos en orden. Simple y aprovecha el espacio; buscar requiere recorrerlo y actualizarlo suele exigir crear otro fichero.
Secuencial encadenada	Un puntero enlaza cada registro con el siguiente. Facilita inserciones y borrados, pero las búsquedas siguen un recorrido secuencial.
Secuencial indexada	Área de datos ordenada por clave, índice de claves y direcciones, más área de desbordamiento. Permite acceso secuencial y directo, a costa de espacio adicional.
Directa o aleatoria	Se localiza mediante posición o clave; rápida y actualizable en el propio fichero. El hashing calcula direcciones y puede generar colisiones, que se resuelven buscando otro hueco o con área de desbordamiento.

Problemas de gestionar solo ficheros: duplicidad e incoherencia; dependencia entre programas y formato de datos; consultas nuevas costosas; datos aislados; concurrencia, integridad y seguridad difíciles. Estos problemas impulsaron las BD y los SGBD.

2. Bases de datos

Una **BD** es una colección de datos lógicamente relacionados, con una descripción común y organizada para reducir redundancia y permitir acceso eficiente. El **SGBD** es el software que define, construye y manipula esa BD: BD son los datos; SGBD es quien los administra.

Las BD aparecieron para separar los datos de los programas y compartir información de forma controlada. El catálogo o diccionario de datos guarda **metadatos** (descripción de tablas, campos, relaciones, índices y permisos).

Ventajas principales

- Acceso compartido y concurrente, con vistas distintas según el usuario.
- Redundancia controlada; más consistencia e integridad.
- Seguridad y confidencialidad mediante usuarios, roles y permisos.
- Independencia física: cambios en el almacenamiento no obligan a cambiar las aplicaciones.
- Independencia lógica: cambios en el diseño pueden aislarse de las vistas y programas.
- Copias y recuperación ante fallos, consultas directas e interfaces de alto nivel.

Quién trabaja con una BD

Administrador (DBA): almacenamiento, índices, seguridad y acceso. **Diseñador:** estructura, relaciones y restricciones.

Programador: crea aplicaciones que consultan y actualizan. **Usuario final:** utiliza la información. Se usan, por ejemplo, en banca, universidades, sanidad, administración, telecomunicaciones, turismo y bibliotecas.

Dónde se almacena

HDD: discos magnéticos mecánicos. **SSD:** memoria flash, acceso rápido. **Cinta:** acceso secuencial, económica y útil para copias masivas. **RAID:** varios discos coordinados: RAID 0 mejora velocidad sin redundancia; RAID 1 duplica datos; RAID 5 distribuye datos y paridad y tolera el fallo de un disco; RAID 6 tolera dos. **NAS** comparte archivos por red; **SAN** ofrece almacenamiento en bloques a servidores. La **nube** ofrece acceso remoto y capacidad flexible, pero depende de la conexión y del proveedor.

3. Evolución de los modelos de BD

Un modelo de datos define cómo se organizan los datos, las relaciones y las restricciones.

Modelo	Estructura / cuándo conviene recordarlo
Jerárquico	Árbol padre-hijo: cada hijo tiene un único padre. Claro y rápido, pero rígido; hoy está en desuso.
En red	Registros conectados por enlaces; permite varios padres y relaciones muchos a muchos, aunque es más complejo.
Relacional	Tablas: filas/tuplas y columnas/atributos; claves primarias identifican filas. Flexible y muy extendido; se consulta con SQL.
Orientado a objetos	Objetos, clases, propiedades y operaciones; incorpora encapsulación, herencia y polimorfismo. Adecuado para datos complejos, pero no sustituyó al relacional.
Documental	Documentos semiestructurados (p. ej. JSON), normalmente sin esquema rígido. Flexible para aplicaciones web; ejemplo: MongoDB.

Otros: objeto-relacional combina tablas con funciones de objetos; deductivo deriva hechos mediante reglas; multidimensional organiza datos en cubos para análisis; transaccional prioriza operaciones fiables que se completan o se cancelan.

4. Sistemas gestores de bases de datos (SGBD)

Un SGBD es un conjunto de programas, lenguajes y procedimientos que permite definir, construir y manipular una BD con eficiencia y seguridad. Gestiona grandes volúmenes, abstrae el almacenamiento, reduce redundancia, valida integridad, comparte accesos y ofrece copias y recuperación.

Funciones y lenguajes

DDL (definición): crea y modifica estructuras, relaciones, restricciones y vistas. **DML (manipulación):** consulta, inserta, modifica y borra datos. **DCL (control):** gestiona usuarios, permisos y seguridad. En BD relacionales, SQL reúne instrucciones de estos tipos.

Componentes

Lenguajes de BD; diccionario de datos con metadatos; gestor central que coordina operaciones; usuarios con distintos privilegios; y herramientas de administración, informes, formularios y desarrollo.

Arquitectura ANSI/SPARC

Interno/físico: cómo se guardan bloques e índices. **Conceptual/lógico:** estructura global, entidades, relaciones y restricciones. **Externo:** vistas específicas para usuarios/aplicaciones. Hay un esquema interno y uno conceptual, y puede haber varios externos. Independencia física = cambiar almacenamiento sin afectar el diseño lógico; lógica = cambiar el diseño global procurando no afectar vistas/programas.

Clasificaciones de SGBD

Pueden ser monousuario o multiusuario; centralizados o distribuidos (homogéneos si usan el mismo SGBD, heterogéneos si usan varios); de propósito general o específico; y gratuitos o de pago.

5. SGBD comerciales y libres

Comerciales citados en la unidad: Oracle, MySQL Standard/Enterprise, DB2, Informix y Microsoft SQL Server; también Access, Interbase, dBase y FoxPro. **Libres/de código abierto:** MySQL Community, MariaDB, PostgreSQL, Firebird, Apache Derby y SQLite.

La elección depende del volumen y carga, sistema operativo, presupuesto, plazos, compatibilidad y necesidades de seguridad y mantenimiento. No existe un SGBD óptimo para todos los proyectos.

6. Bases de datos centralizadas

El SGBD y los datos residen en un único ordenador o plataforma. Facilita administración, control, integridad y evita duplicaciones por copias dispersas. Puede ser más sencillo y económico de mantener. Sus límites: capacidad ligada a una máquina, concentración de la carga y punto único de fallo; una avería puede dejar sin servicio o dificultar la recuperación.

7. Bases de datos distribuidas

Una **BD distribuida** es un conjunto de bases lógicamente relacionadas almacenadas en nodos conectados por una red. El SGBD distribuido procura que el usuario las perciba como un único sistema.

Ventajas y costes

Puede repartir procesamiento, acercar datos a usuarios, escalar, permitir acceso remoto y mantener disponibilidad ante el fallo de un nodo (por ejemplo, con replicación). A cambio, requiere coordinación y sincronización, complica concurrencia y recuperación, aumenta la superficie de seguridad y puede encarecer el mantenimiento.

7. Bases de datos distribuidas (continuación)

Fragmentación

Se divide una relación para colocar sus partes en distintos nodos. **Horizontal:** separa filas mediante criterios de selección; se reconstruye uniendo fragmentos. Puede ser primaria o derivada (esta última sigue la fragmentación de una tabla relacionada). **Vertical:** separa columnas y repite la clave primaria en cada fragmento para poder recomponer filas. **Mixta:** combina horizontal y vertical. La fragmentación funcional agrupa los datos según las funciones habituales.

Tres reglas: completitud (no perder datos); reconstrucción (poder recomponer la relación original); disyunción (evitar duplicar datos, salvo claves necesarias). Se busca un equilibrio que mejore consultas y distribución sin fragmentar en exceso.

8. Protección de datos: RGPD y LOPDGDD

Dato personal es información sobre una persona física identificada o identificable. Los datos sensibles incluyen origen racial o étnico, opiniones políticas, religión, afiliación sindical, genética, biometría identificativa, salud y vida u orientación sexual. La protección de datos es un derecho fundamental.

El **RGPD** (Reglamento UE 2016/679) fija el marco común europeo. La **LOPDGDD** (Ley Orgánica 3/2018) lo complementa en España y recoge derechos digitales. La normativa se centra en cómo se tratan los datos, no solo en los ficheros donde se guardan.

Principios que hay que saber

Licitud, lealtad y transparencia; finalidad determinada; minimización (solo lo necesario); exactitud; conservación limitada; integridad y confidencialidad; y responsabilidad proactiva (poder demostrar cumplimiento).

Derechos, obligaciones y seguridad

Las personas pueden ejercer acceso, rectificación, supresión, limitación, portabilidad y oposición, además de garantías ante decisiones automatizadas. La organización debe establecer una base válida para tratar datos, informar, limitar accesos, aplicar medidas técnicas y organizativas, llevar registros y evaluar riesgos cuando corresponda. Se designa DPO/DPD en ciertos supuestos, como autoridades públicas y tratamientos a gran escala de datos sensibles o monitorización sistemática. Las brechas se notifican a la autoridad en el plazo previsto (el material destaca 72 horas). La AEPD supervisa en España.

Medidas típicas: control de acceso, autenticación, cifrado, copias de seguridad, protección física, políticas internas y acuerdos con encargados del tratamiento.

9. Big Data

Big Data trata volúmenes de datos tan grandes, rápidos o variados que las herramientas tradicionales no bastan. Puede combinar datos estructurados, semiestructurados y no estructurados.

Las 5 V

Volumen: cantidad. **Velocidad:** generación y procesamiento. **Variedad:** formatos y fuentes. **Veracidad:** calidad y fiabilidad. **Valor:** utilidad obtenida del análisis.

Tipos de datos

Estructurados: esquema fijo, habitualmente tablas; fáciles de consultar con SQL. **Semiestructurados:** etiquetas/metadatos sin tabla rígida, como XML o JSON. **No estructurados:** texto libre, documentos, imágenes, audio y vídeo; requieren procesamiento antes del análisis.

Análisis de datos

Descriptivo: qué ocurrió. **Diagnóstico:** por qué ocurrió. **Predictivo:** qué podría ocurrir. **Prescriptivo:** qué acción conviene. Flujo típico: recopilar, almacenar, limpiar/preparar, explorar, modelar, interpretar y comunicar.

Tecnologías citadas: Hadoop y HDFS para almacenamiento/procesamiento distribuido; Spark para procesamiento; bases NoSQL (p. ej., MongoDB o Cassandra) para datos flexibles; herramientas de aprendizaje automático para modelos.

Inteligencia de negocio (BI)

BI aplica análisis a las necesidades de decisión de una empresa. **ETL** extrae datos de fuentes, los transforma y los carga en un **almacén de datos**. Las herramientas BI los convierten en informes y cuadros de mando. El proceso integra fuentes, analiza y visualiza resultados para apoyar decisiones. Beneficios: decisiones mejor informadas, optimización de procesos, eficiencia y detección de oportunidades. Retos: integrar fuentes, mantener calidad, proteger datos y escalar.